ГУАП

КАФЕДРА № 42

ОТЧЕТ

ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук		В. В. Фомин
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №2

МЕТОД К-БЛИЖАЙШИХ СОСЕДЕЙ

по курсу: Методы искусственного интеллекта

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. №	4321		И.А. Лаврешин
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2026

1 Цель работы

Изучение основ организации работы с технологической платформой KNIME Analytics Platform для создания законченных аналитических решений с использованием метода k-ближайших соседей (K-Nearest Neighbors, KNN) применительно к задаче классификации.

2 Задание

Для набора данных Iris реализовать классификацию методом k-ближайших соседей в KNIME. Выполнить оценку качества классификации (матрица сопряжённости, accuracy и связанные метрики). Разработать визуальные отчёты (фрагмент классификации, Scorer, Scatter Plot) для анализа результатов.

3 Краткие теоретические сведения

Алгоритм k-ближайших соседей относится к методам обучения с учителем и основан на гипотезе локальности: объекты одного класса располагаются близко в пространстве признаков. Для нового объекта находятся k ближайших обучающих объектов (по евклидову расстоянию для числовых признаков), после чего класс назначается голосованием соседей. При k = 1 модель теряет обобщающую способность; при слишком большом k границы классов чрезмерно сглаживаются. В практикуме для небольшой выборки Iris рекомендовано значение k = 15.

Качество классификации оценивается матрицей сопряжённости и метриками Accuracy, Precision, Recall, F-measure. Accuracy показывает долю верных прогнозов на тестовой выборке.

4 Входные данные

Использован классический набор данных о цветках ириса (Iris Flower Dataset, 150 записей, по 50 образцов каждого из трёх видов). Источник — репозиторий, рекомендованный в методических указаниях (https://www.kaggle.com/datasets/arshid/iris-flower-dataset).

Атрибуты набора данных:

– Id — порядковый номер наблюдения,

– sepal_length, sepal_width — длина и ширина чашелистика (см),

– petal_length, petal_width — длина и ширина лепестка (см),

– species — вид ириса (Iris-setosa, Iris-versicolor, Iris-virginica) — целевой класс.

Обучение выполнялось по всем четырём числовым признакам без дополнительного отбора (как в примере практикума).

5 Ход выполнения работы

В KNIME Analytics Platform создан workflow Lab2_KNN. В рабочую область добавлены и соединены узлы: CSV Reader → Color Manager → Partitioning → K Nearest Neighbor → Scorer и Scatter Plot.

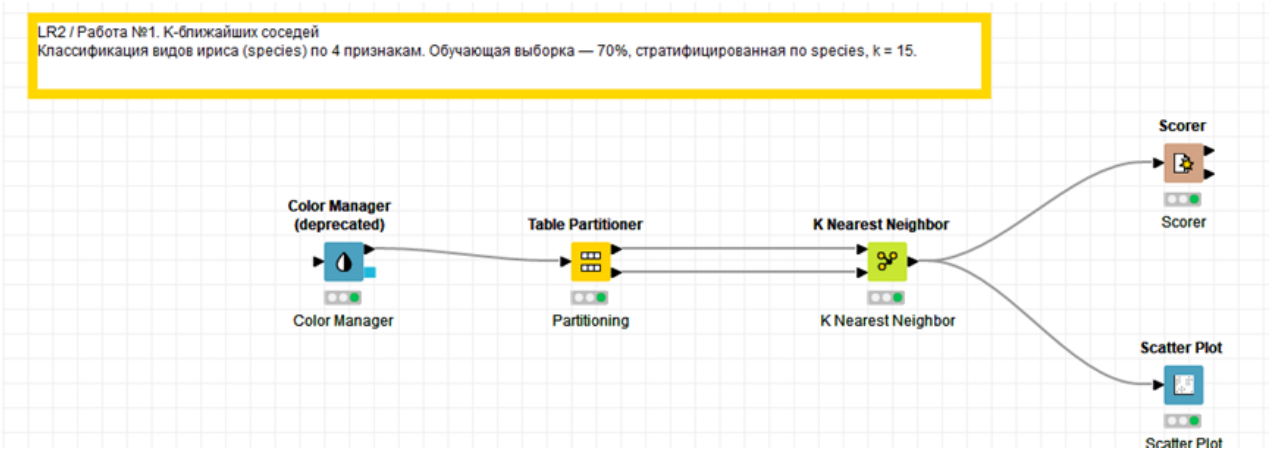


Рисунок 1 – Схема workflow классификации методом KNN

Назначение основных узлов:

– CSV Reader — загрузка файла Iris.csv,

– Color Manager — назначение цветов по столбцу species для наглядной визуализации,

– Partitioning — разделение на обучающую (70 %) и тестовую (30 %) выборки, метод — стратифицированная выборка по species,

– K Nearest Neighbor — классификация; столвой атрибут species, число соседей k = 15,

– Scorer — сравнение фактического класса species с прогнозом Class [kNN], построение матрицы сопряжённости,

– Scatter Plot — точечная диаграмма распределения видов в пространстве признаков.

Объём выборок: обучающая — 105 наблюдений, тестовая — 45 наблюдений (доля обучения 70 %, стратификация по species).

6 Результаты эксперимента

На рисунке 2 представлен фрагмент результата классификации тестовой выборки. В столбце species показаны истинные метки класса, в столбце Class [kNN] — предсказания модели. Строки с расхождением классов выделены (отклонения классификации).

Fragment of classified test sample (species vs Class [kNN])

Row	sepal_length	sepal_width	petal_length	petal_width	species	Class [kNN]
1	7.3	2.9	6.3	1.8	Iris-virginica	Iris-virginica
2	6.1	2.9	4.7	1.4	Iris-versicolor	Iris-versicolor
3	6.3	2.8	5.1	1.5	Iris-virginica	Iris-virginica
4	6.3	3.3	4.7	1.6	Iris-versicolor	Iris-versicolor
5	6.1	3.0	4.9	1.8	Iris-virginica	Iris-virginica
6	6.7	3.1	5.6	2.4	Iris-virginica	Iris-virginica
7	5.5	2.3	4.0	1.3	Iris-versicolor	Iris-versicolor
8	5.6	2.5	3.9	1.1	Iris-versicolor	Iris-versicolor
9	5.4	3.4	1.7	0.2	Iris-setosa	Iris-setosa
10	6.9	3.1	5.1	2.3	Iris-virginica	Iris-virginica
11	5.8	4.0	1.2	0.2	Iris-setosa	Iris-setosa
12	4.4	3.0	1.3	0.2	Iris-setosa	Iris-setosa

Рисунок 2 – Фрагмент классифицированных данных тестовой выборки

Всего на тестовой выборке выявлено 2 отклонений (несовпадений species и Class [kNN]).

Результат оценки классификатора представлен на рисунке 3. Получено 43 правильных прогнозов и 2 ложных срабатываний. Таким образом, точность попадания составляет 95,56 %.

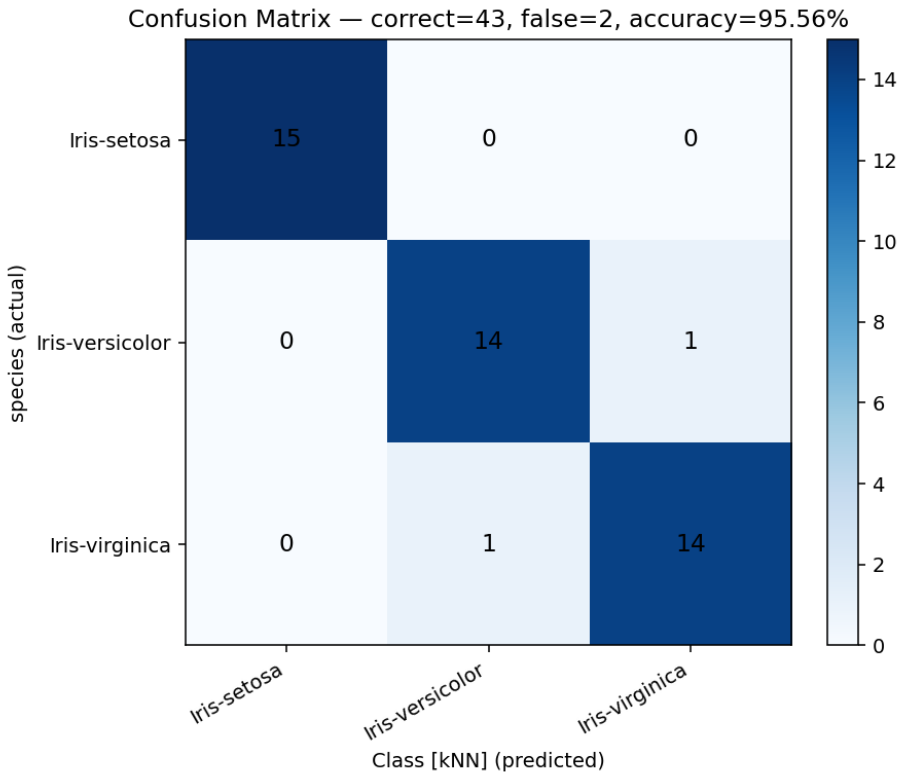


Рисунок 3 – Матрица сопряжённости

Во вкладке Accuracy statistics узла Scorer доступны основные метрики качества по классам (Precision, Recall, F-measure) и сводная Accuracy (рисунок 4).

Accuracy statistics (Scorer)

Class	Precision	Recall	F-measure	Support
Iris-setosa	1.000	1.000	1.000	15
Iris-versicolor	0.933	0.933	0.933	15
Iris-virginica	0.933	0.933	0.933	15
Overall Accuracy	0.9556	95.56%	Correct=43	False=2

Рисунок 4 – Метрики оценки качества классификации

Таблица 1 – Метрики качества по классам на тестовой выборке

Класс	Precision	Recall	F-measure	Support
Iris-setosa	1,000	1,000	1,000	15
Iris-versicolor	0,933	0,933	0,933	15

Класс	Precision	Recall	F-measure	Support
Iris-virginica	0,933	0,933	0,933	15

Анализ по классам показывает, что Iris-setosa обычно отделяется практически безошибочно (признаки лепестка сильно отличаются). Основные ошибки, как правило, возникают на границе Iris-versicolor и Iris-virginica, где распределения признаков частично перекрываются.

На рисунке 5 представлена визуализация распределения данных узлом Scatter Plot (оси petal_length и petal_width). По диаграмме видно разделение видов и область пересечения классов versicolor/virginica, где возможны ошибки KNN.

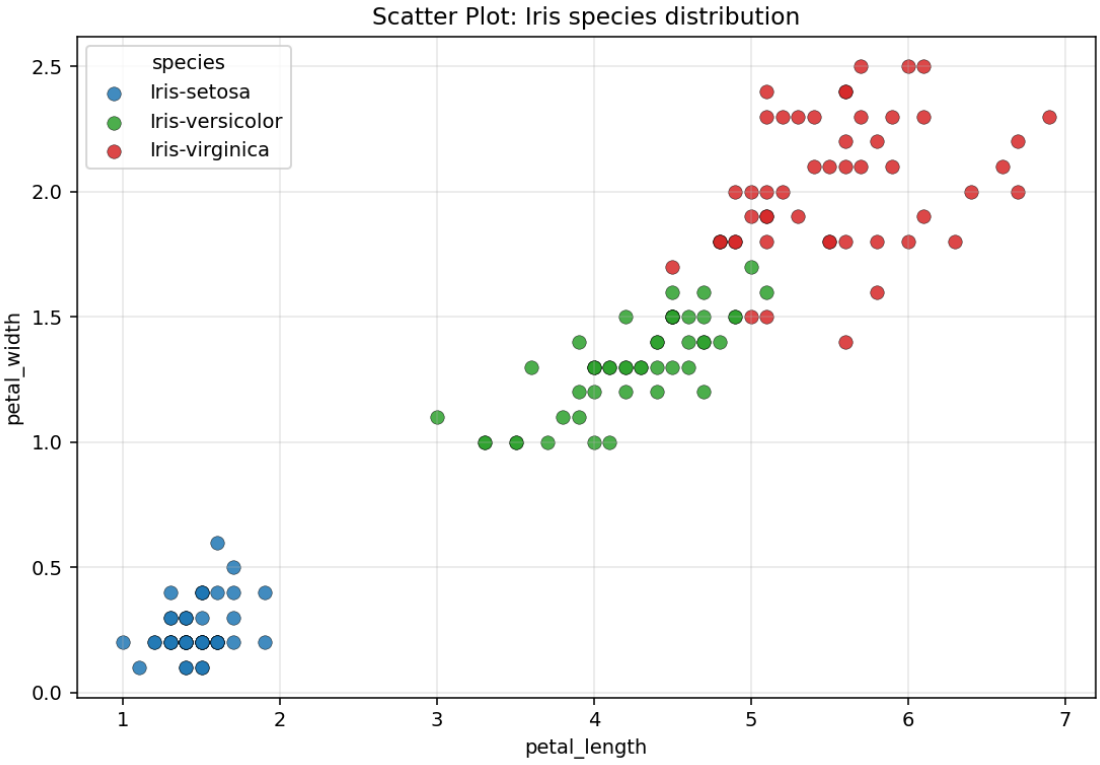


Рисунок 5 – Точечный график распределения видов ириса

7 Выводы

В ходе лабораторной работы изучены основы работы с KNIME Analytics Platform и реализована классификация методом k-ближайших соседей на наборе Iris (150 наблюдений, 4 признака, 3 класса). При k = 15, обучающей доле 70 % и стратифицированном разбиении по species на тестовой выборке получено 43 верных и 2 ошибочных прогнозов, accuracy ≈ 95,56 %. Освоен полный цикл загрузки данных, разбиения выборки, обучения/применения KNN, оценки качества и визуализации.