

Краткий конспект — экзамен «Большие данные»

Формат: 2 устных вопроса — один из №1–10, второй из №11–20. Учитывается ЛР9.

Главное: формулы не зубрить — понимать смысл, диапазоны, когда что применять. К каждому ответу добавляй опыт из лаб (1–2 предложения).

Блок 1: Основы и подготовка данных (вопросы 1–10)

1. Big Data, BA, KDD, Data Mining, ML

6V Big Data: Volume (>150 Гб/сут), Velocity, Variety (структ./неструкт./слабострукт.), Variability, Veracity, Value.

Области: ритейл (корзина, ABC/XYZ), банки (скоринг, фрод), медицина, телеком, безопасность.

Термин	Суть
BA	Бизнес-аналитика: сбор → фильтрация → преобразование → моделирование → решения
KDD	Полный цикл: подготовка → отбор признаков → очистка → модели → интерпретация
Data Mining	«Ядро» KDD (Пятецкий-Шапиро, 1989): новые, нетривиальные, полезные, интерпретируемые знания из сырых данных
ML	Модели обучения: линейная/логистическая регрессия, деревья, SVM

3 принципа знаний DM: отражают результат исследования; понятны человеку; компактны.

2. Жизненный цикл BA

1. **Подготовка и очистка** (до 80% времени DM) — пропуски, выбросы, дубликаты
2. **Feature engineering** — новые признаки, кодирование, нормализация, биннинг
3. **Разбиение** — train / valid / test (в ЛР8: 70:15:15, seed=42)
4. **Построение** — *fit* на train
5. **Оценка** — R^2 , MSE, F1, ROC-AUC на test
6. **Эксплуатация** — *predict*, *predict_proba* на новых данных

Инструменты: Loginom, pandas, scikit-learn, Silver Kit, Python Kits.

3. Требования к данным

Формы: структурированные (число, строка, да/нет, дата); неструктурированные (текст, видео — нужна структуризация); слабоструктурированные (ФИО, адрес).

Шкалы: номинальная (категории без порядка) → порядковая (ранг) → интервальная/отношений (арифметика).

Дискретные vs непрерывные — можно ли считать среднее/сумму.

Информативность — признак должен помогать задаче; слабые отсекают ($IV < 0,02$).

Важно сказать: данные не собирают специально — регистрируются в бизнесе; в вопросах 3–4 упомянуть **устранение аномалий**.

4. Подготовка данных и визуализация

Сбор: учётные системы, открытые источники, покупка, ручной ввод, косвенные признаки.

Предобработка: заполнение пропусков (**медиана** устойчивее среднего), выбросы (2–4 σ или процентиля), **нормализация** [0;1], **стандартизация** Z ($\mu=0$, $\sigma=1$), кодирование, агрегаты.

Визуализация на EDA: гистограммы (распределения), scatter (корреляции), выявление аномалий, проверка гипотез.

5. Консолидация данных (Loginom)

Консолидация — сбор из разных источников в единое представление. Критерии: скорость, компактность, целостность.

Источники: файлы, СУБД, **ХД (предпочтительно)**.

Цикл: выбор источников → стратегия → оценка качества → **обогащение** → очистка.

Операции Loginom:

- **Соединение** — столбцы по ключу
- **Слияние:** внутреннее / левое / правое / полное / разность
- **Дополнение** — строки «снизу»
- **Объединение** — в один набор

6. Трансформация

Группировка (агрегаты), свёртка столбцов (unpivot), фильтры, слияние, **биннинг**, **нормализация**, **кодирование** (0/1, нумерация, WoE).

Скажи, что делали и в Loginom, и в Python (ЛР1, ЛР3).

7. Визуализация, OLAP

Общие: Таблица, Статистика, Диаграмма (линии, столбцы).

Специализированные (перечислить все!):

- **Куб (OLAP)** — измерения, факты, срезы, фильтры
- Профили кластеров, **кластерные силуэты**
- **ROC-кривая, WoE-диаграммы**, диаграмма рассеяния

OLAP — оперативный многомерный анализ через гиперкубы.

Проблемы визуализации: большая размерность, структуры, связи, контроль обучения, ошибка прогноз vs факт.

8. Очистка, качество, размерность

Мешают анализу: ошибки ввода, пропуски, аномалии, шум, дубликаты, противоречия.

Пропуски: удаление (по порогу) или **заполнение** (медиана, среднее, WoE соседа).

Выбросы: σ , IQR, **clipping** (ограничение, не удаление).

Сокращение размерности:

- признаков — корреляция с Y, $IV < 0,02$, Ridge/LASSO
- записей — фильтрация, агрегация
- **биннинг** — меньше уникальных значений

LOF полностью не нужен — можно упомянуть.

9. KDD и Data Mining

KDD = весь процесс от данных до интерпретации.

DM = ядро: 4 свойства знаний (новые, нетривиальные, полезные, интерпретируемые).

Этапы DM: получение → очистка → преобразование → модели → интерпретация.

Отличие от статистики: DM работает с **паттернами для каждого объекта**, не только «в среднем».

Задачи: ассоциация, кластеризация, классификация, регрессия.

Главный акцент: DM находит **ранее неизвестные** знания.

10. Модели и задачи DM

Тип	Примеры
Описательные	Профиль клиента, структура базы, связи
Предсказательные	Отклик клиента, прибыль, спрос

Свойства методов: с/без учителя, интерпретируемость, устойчивость к выбросам, сложность, типы шкал.

Важно: DM не отвечает на незадаанные вопросы, не заменяет аналитика, нужна проверка на test.

Блок 2: Методы анализа (вопросы 11–20)

11. Ассоциативные правила

Задача: $X \rightarrow Y$ (market basket). Пример: помидор $\rightarrow$ огурец.

Алгоритмы: AIS, SETM, **Apriori** (1994), AprioriTID/Hybrid, DHP, PARTITION, DIC.

Apriori: антимонотонность — если набор частый, все подмножества частые. Два шага: кандидаты + подсчёт support.

Метрики:

- **Support** $S(A \rightarrow B)$ — доля транзакций с A и B
- **Confidence** $C(A \rightarrow B) = S(A \cup B) / S(A)$
- **Lift** $= C / S(B)$: >1 связь, $=1$ независимы, <1 отрицательная
- **Leverage** $= S(A \rightarrow B) - S(A) \cdot S(B)$
- **Improvement** $= S(A \rightarrow B) / (S(A) \cdot S(B))$: >1 полезнее случайного

3 типа правил: полезные / тривиальные (лидеры) / непонятные (нужен доп. анализ).

Support не выше ~20%, иначе тривиально. Метрики — **аналитика**, не ML.

12. Кластерный анализ 🚩 силуэты обязательно!

Задача: группы похожи внутри, различны снаружи. **Без учителя.**

Методы: иерархические (Diana, Agnes, BIRCH), смесь распределений (EM, GMM), плотностные (DBSCAN, OPTICS), **k-means**, k-medoids, g-means, CLOPE.

Расстояния: Евклид, Манхэттен, Чебышёв. **Перед расчётом — стандартизация/нормализация!**

k-means: k задано заранее, минимизирует WCSS. Плохо на «пончиках» и эллипсах.

g-means: авто-выбор k (нормальность).

Выбор k: экспертно, локоть (WCSS vs k), **силуэты**.

Силуэт S: [-1; 0,2] плохо, (0,2; 0,5) средне, [0,5; 1] хорошо. Оценка качества + выбор k + визуализация.

13. Классификация

Задача: предсказать **y** (конечные классы) по **x**. **С учителем.**

Формы модели: правила «если $\rightarrow$ то», деревья решений, мат. функции (веса ω).

ABC-анализ (Парето 20/80): A $\approx$ 80% эффекта, B $\approx$ 15%, C $\approx$ 5%.

ABC + XYZ → матрица 9 групп (AX — ценные и стабильные, CZ — слабые).

ABC по периодам — динамика категорий.

Акцент: ABC на **правилах**; регрессия — про **шансы** (след. билеты).

14. Линейная регрессия

$Y = b_0 + b_1x_1 + \dots + b_nx_n$. МНК минимизирует RSS (сумму квадратов остатков).

Термины: отклик Y , предикторы X , остатки, подогнанные значения.

Проблемы предикторов: мультиколлинеарность, коррелированные X , confounding (пропущенный важный фактор).

Отбор/регуляризация: Enter, Forward, Backward, Stepwise; **Ridge** (L2, мультиколлин.), **LASSO** (L1, отбор), **Elastic-Net**.

Метрики: R^2 (0...1, доля объяснённой дисперсии), MSE/RMSE, MAE.

Интерпретация: b_i — на сколько меняется Y при +1 к x_i . Чувствительна к выбросам.

Рассказывай **свою** регрессию из лабы (ЛР6).

15. Нелинейная регрессия

Когда связь Y – X нелинейна.

Виды: полиномиальная ($x^2, x^3 \dots$), **сплайны** (кусочные полиномы), GAM.

Линеаризация: $x^2 \rightarrow$ новый признак $\rightarrow$ обычная линейная регрессия.

Те же проблемы факторов и Ridge/LASSO/Elastic-Net. Метрики: R^2 , MSE, MAE.

16. Логистическая регрессия

Бинарная классификация через вероятность (сигмоида). GLM.

Шансы: $\text{odds} = p/(1-p)$; **logit** = $\ln(\text{odds})$ — линеен, без верхней границы 1.

exp(β): при $\beta=0,5 \rightarrow \exp(0,5) \approx 1,65$ — шансы события растут в 1,65 раза при +1 к x .

Метрики: TPR (recall), TNR (специфичность), PPV, **ROC, AUC**, порог отсечения.

Акцент: логистическая регрессия — про **шансы**, уметь объяснить $\exp(\beta)$.

17. Биннинг, WoE, IV

Биннинг — числа/категории → интервалы (бины). Цели: меньше шума, пропуски, выбросы, предсказательная сила.

Без учителя: равная ширина, равная частота.

С учителем (Optimal Binning): MAPA (IV), MID (энтропия), Chi-Merge, Conditional Inference Trees.

Classing: Fine Classing (каждое значение = класс) → **Coarse Classing** (объединение с max IV, ≤ 10 бинов, min доля в бине).

WoE: $WoE < 0$ → больше событий; $WoE > 0$ → больше не-событий.

IV (сила переменной):

IV	Значимость
<0,02	нет — исключить
0,02–0,1	слабая
0,1–0,3	средняя
0,3–0,5	высокая
$\geq 0,5$	очень высокая (IV>2 — проверить утечку)

Отвод (woe binning) — редкие/новые значения в отдельный бин.

18. DM vs ML, модель, этапы

	Data Mining	Machine Learning
Роль человека	Аналитик участвует (интерпретация, отбор)	Автоматическое обучение
Результат	Новые знания	Настроенная модель

Модель — параметры после *fit* (коэффициенты, веса, правила). Применение: *predict, transform, predict_proba*.

Этапы ML (обязательные ^):

7. Подготовка и очистка^
8. Feature engineering
9. Разбиение train/valid/test^
10. Кодирование и стандартизация
11. Построение модели^
12. Оценка качества^
13. Эксплуатация

Python: sklearn (LinearRegression, LogisticRegression, KMeans, LOF и др.).

19. Аномалии и LOF

Причины: ошибки измерения, загрязнение, поломка датчика, мошенничество.

Зачем: EDA, улучшение моделей, самостоятельная задача (фрод, диагностика).

Типы: точечная (возраст 150), контекстная (28°C зимой в Питере), коллективная (участок ЭКГ, серия транзакций).

LOF (Local Outlier Factor):

- Идея: у аномалии мало соседей, низкая локальная плотность
- LOF ≈ 1** — норма; **LOF $\gg 1$** — аномалия
- Параметры: *n_neighbors* (k), *contamination* (c), *novelty* (false=fit_predict на train; true=обучение на чистых, скоринг новых)
- Метрики: Precision, Recall, **F1**, F β ($\beta > 1$ — важнее не пропустить FN)

ЛР8: ECG5000, novelty=true, 70:15:15, F β с $\beta=4$.

20. Задачи ML и метрики

Задача	Метрики
Классификация	Accuracy*, Precision, Recall, F1, F β , ROC-AUC, confusion matrix
Регрессия	R ² , MSE, RMSE, MAE
Кластеризация	Силуэты, локоть, WCSS
Ассоциации	Support, Confidence, Lift (аналитика)

*Accuracy обманчива при дисбалансе.

Confusion matrix: TP, TN, FP (ошибка I рода), FN (ошибка II рода).

Когда что важнее:

- Медицина** — FN опаснее $\rightarrow$ Recall, F β ($\beta > 1$)
- Спам/скоринг** — FP дорого $\rightarrow$ Precision
- Фрод/аномалии** — F1, F β , ROC-AUC

Loginom: classification_metrics, regression_metrics, meta-silhouettes, ROC.

Шпаргалка «что сказать обязательно»

Вопрос	Акцент преподавателя
3, 4, 8	Устранение anomalies
7	Все спец. визуализаторы
9	DM = неизвестные знания
12	Кластерные силуэты — подробно
13	ABC = правила; регрессия = шансы
14–16	Своя регрессия из лабы + метрики
16	exp(β) для шансов
17	WoE, IV, Coarse Classing
18	DM vs ML, этапы ML
19	LOF, параметры, F β

20	Какая ошибка дорожке в кейсе
----	------------------------------

Связь с лабораторными (одной строкой на ЛР)

ЛР	Тема
ЛР1	Группировка, свёртка, диаграммы, OLAP-куб
ЛР2	Ассоциативные правила, Apriori, support/confidence
ЛР3	Пропуски, выбросы, нормализация (Logitom + Python)
ЛР4	k-means, g-means, EM, силуэты, «локоть»
ЛР5	ABC-классификация, по периодам
ЛР6	Линейная, полиномиальная, логистическая регрессия, ROC
ЛР7	WoE, IV, биннинг, логистическая регрессия
ЛР8	LOF, ECG, Fβ
ЛР9	Полный цикл: БД → очистка → модель → скоринг

Удачи на экзамене!