ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ

ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук		Н.В. Богословская
должность, уч. степень, звание	подпись, дата	инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №4

ПЛАТФОРМА LOGINOM

по курсу: БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. №	4321		И.А. Лаврешин
		подпись, дата	инициалы, фамилия

Санкт-Петербург 2026

1. Цель работы

Изучение методов кластеризации с использованием инструментов Loginom.

2. Задание

В рамках данной работы необходимо реализовать кластеризацию для двух наборов данных — “Высшее образование.xls” и “Здравоохранение.xls” — с использованием алгоритмов EM, k-means и g-means. Для набора данных “transactions_diy.lgd” требуется выполнить кластеризацию транзакций. После построения моделей необходимо провести оценку качества всех полученных результатов, предложить интерпретацию сформированных кластеров, а также разработать визуальные отчеты для пользователя, позволяющие наглядно изучить полученные кластеры.

3. Ход работы

В рамках решения задания была разработана схема, изображенная на рисунках 1 – 3.

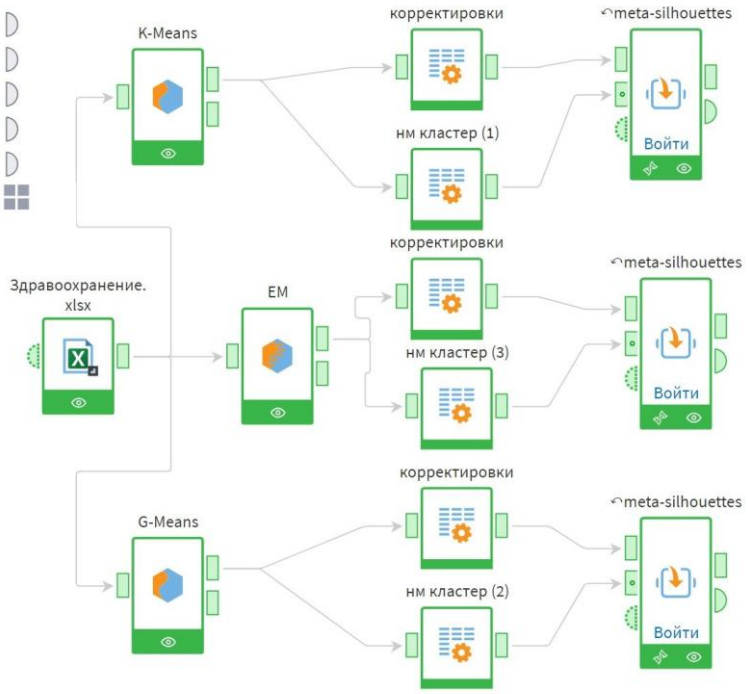

Рисунок 1 – Полученная схема, часть 1

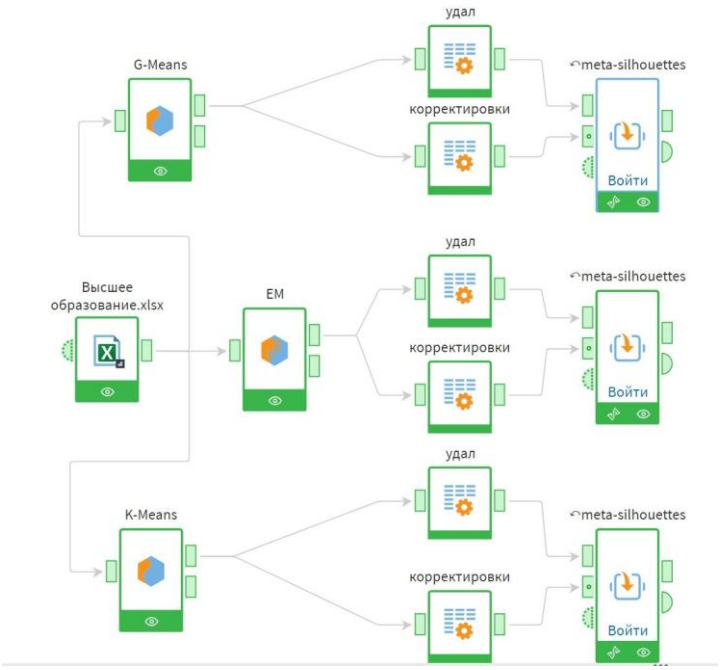

Рисунок 2 – Полученная схема, часть 2

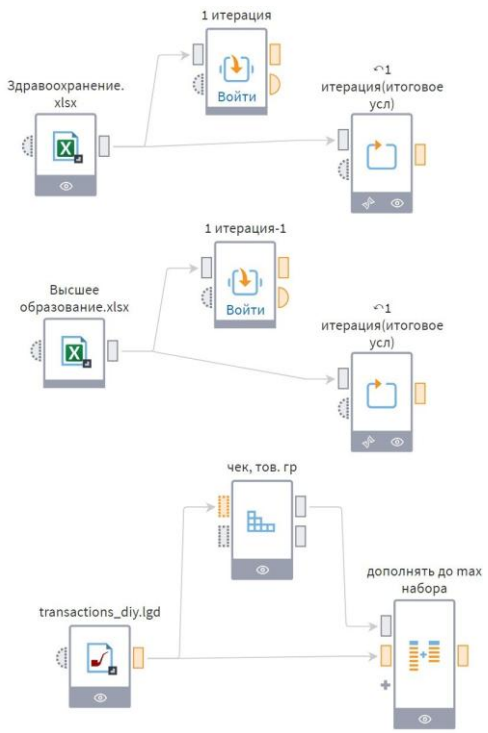

Рисунок 3 – Полученная схема, часть 3

Для определения числа кластеров k в рамках метода K-means использовался подход "локтевой" эвристики. Соответствующий вычислительный модуль позволил установить оптимальное значение данного параметра, представлено на рисунке 4.

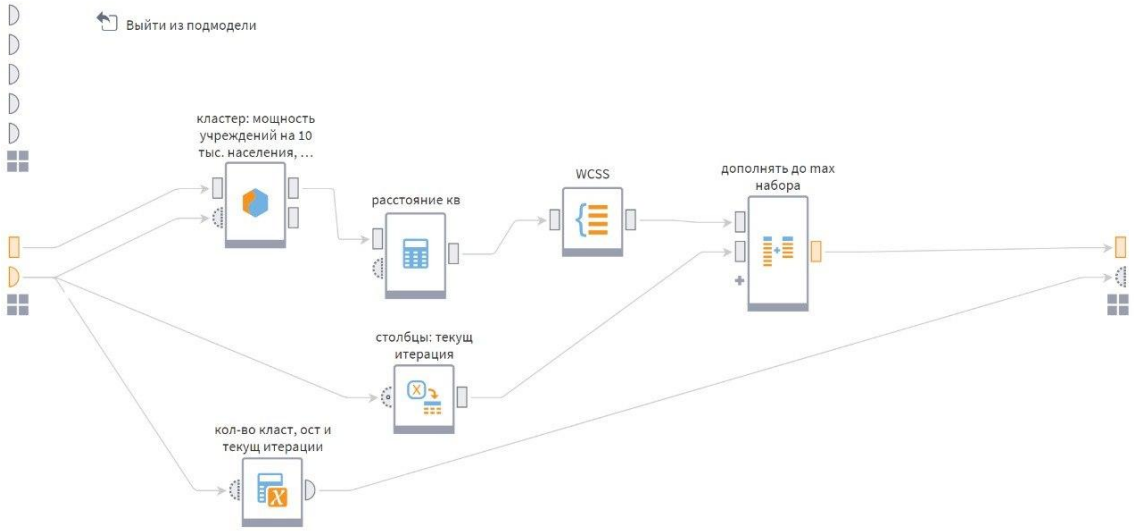

Рисунок 4 – Модуль для определения параметра k

На рисунках 5 и 6 приведены итоговые показатели, полученные в ходе анализа данных по здравоохранению.

1 итерация • Быстрый просмотр

Таблица 1 | Переменные 1

9.0 Квадрат расстония|Сумма	12 Текущая итерация	12 Количество кластеров
219,98	0	2
162,77	1	3
134,56	2	4
117,29	3	5
105,34	4	6
92,52	5	7
85,18	6	8
80,48	7	9

Рисунок 5 – Вычисление метода "локтя" (здравоохранение)

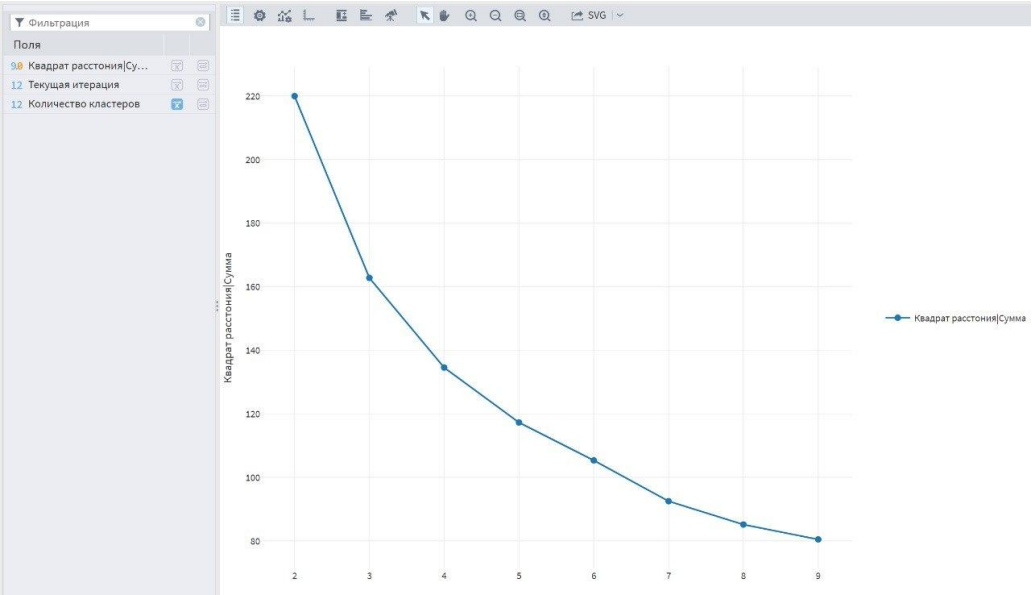

Рисунок 6 – График метода "локтя" для данных здравоохранения

Анализ графика позволяет заключить, что оптимальное число кластеров составляет 3 или 4 – данные точки соответствуют моменту, когда динамика снижения параметра теряет свою интенсивность. Для образовательных данных были выполнены аналогичные расчеты, представленные на рисунках 7 – 8.

1 итерация • Быстрый просмотр

Таблица 1 | Переменные 1

9.0 Квадрат расстония|Сумма	12 Текущая итерация	12 Количество кластеров
274,46	0	2
211,96	1	3
171,81	2	4
137,27	3	5
118,06	4	6
100,48	5	7
82,24	6	8
74,84	7	9

Рисунок 7 – Применение метода "локтя" к образовательным данным

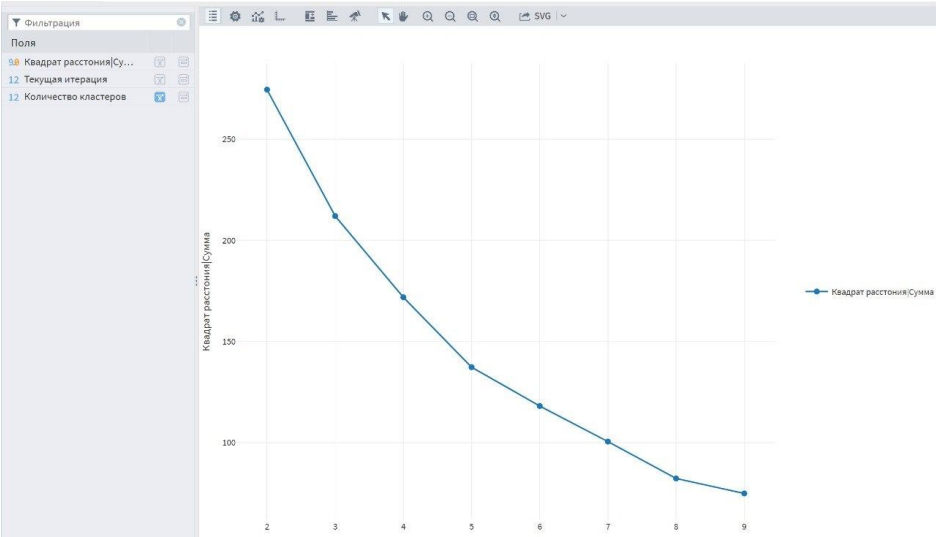

Рисунок 8 – Визуализация метода "локтя" по данным образования

Построенная зависимость не демонстрирует участка с явным замедлением убывания показателя, что позволило остановиться на двух кластерных центрах. Следует отметить, что метод G-Means при автоматическом подборе параметра дал сопоставимые числовые значения, что позволяет в дальнейшем унифицировать описание полученных результатов.

Результаты кластеризации медицинских данных с указанием центров кластеров приведены на рисунке 9. Коэффициент силуэта, равный 0,43, свидетельствует о среднем уровне обособленности кластеров. Выявленное значение, вероятно, объясняется высокой долей пограничных наблюдений, визуализированных на рисунке 10.

Н.	Мощность ...	Численность населения на ...	Обеспеченность врачами ...	Обеспеченность средним медицинским персоналом ...
0	204,64	147,55	38,62	90,55
1	276,08	117,84	45,14	110,08
2	335,60	96,67	59,03	135,92

Рисунок 9 – Центры кластеров здравоохранения (K-means и G-Means)

	Имя	Метка	Значение
1	SilhouetteCoefficient	Индекс силуэта	0,43
2	Quality	Качество кластеризации	Среднее

Рисунок 10 – Оценка качества кластеризации

Согласно графику силуэта, представленного на рисунке 11, выделяются три кластера, при этом межкластерные границы характеризуются ненулевыми значениями. Данный факт свидетельствует о частичном наложении кластеров

друг на друга, то есть о существовании пограничных наблюдений, не поддающихся однозначному отнесению к какой-либо группе.

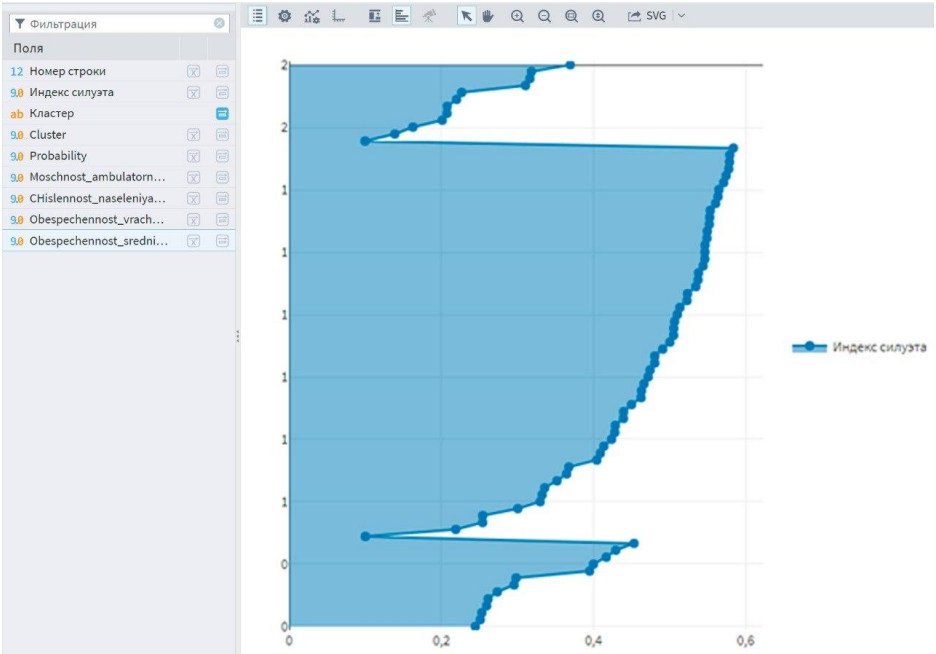

Рисунок 11 – Силуэтный график

Предложенная кластеризация позволяет выделить три типологические группы регионов. К первой относятся территории с низким уровнем доходов, отличающиеся сниженными показателями мощности амбулаторно-поликлинических учреждений, недостаточной укомплектованностью медицинским персоналом и повышенной нагрузкой на больничные койки. Вторую группу формируют среднеразвитые регионы, для которых характерно отсутствие острых проблем в кадровой сфере, а также в распределении нагрузки на персонал и коечный фонд. Третья группа представлена высокоразвитыми субъектами с наибольшими значениями мощности АПУ, оптимальным распределением нагрузки на медицинских работников (что, вероятно, обусловлено их достаточным количеством) и благополучной ситуацией с коечным фондом.

В качестве альтернативного подхода была выполнена кластеризация EM-методом, результаты которой отличаются от приведенных выше и представлены на рисунках 12 – 14.

кластера	Мощность амбулаторно-...	Численность населения на о...	Обеспеченность врачам...	Обеспеченность средним ме...
0	287,53	118,62	46,08	111,37
1	262,46	120,10	46,19	110,29

Рисунок 12 – Центры кластеров здравоохранения (EM-алгоритм)

Имя	Метка	Значение
SilhouetteCoefficient	Индекс силуэта	0,24
Quality	Качество кластеризации	Среднее

Рисунок 13 – Качество модели

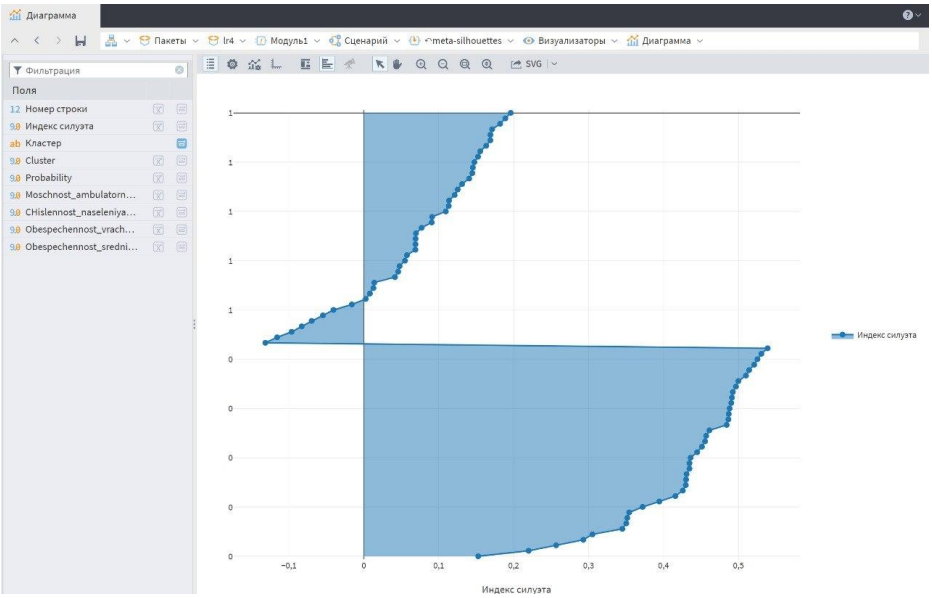

Рисунок 14 – График силуэтного индекса

Интерпретация данных затруднена по следующей причине: кластерные центры обладают крайне близкими значениями, а на графике силуэта наблюдается скопление значений, близких к нулю, в пределах одного из кластеров.

Для данных здравоохранения были проведены аналогичные расчеты. Центры кластеров, оценка качества модели и график силуэтного индекса, полученные при использовании k-means, приведены на рисунках 15 и 16.

тера	1. Число образовательных организа...	2. Численность студенто...	3. Прием на о...	4. Выпуск ба...	5. Численность про...
0	13,47	255,78	62,05	67,71	54,37
1	14,26	451,60	120,27	118,43	60,06

Рисунок 15 – Кластерные центры по здравоохранению (k-means и g-means)

Имя	Метка	Значение
SilhouetteCoefficient	Индекс силуэта	0,50
Quality	Качество кластеризации	Среднее

Рисунок 16 – Оценка качества кластеризации

Анализ графика силуэта, представленного на рисунке 17, позволяет идентифицировать два кластера, однако ненулевые значения на их границе свидетельствуют о перекрытии и наличии пограничных случаев, затрудняющих однозначную классификацию.

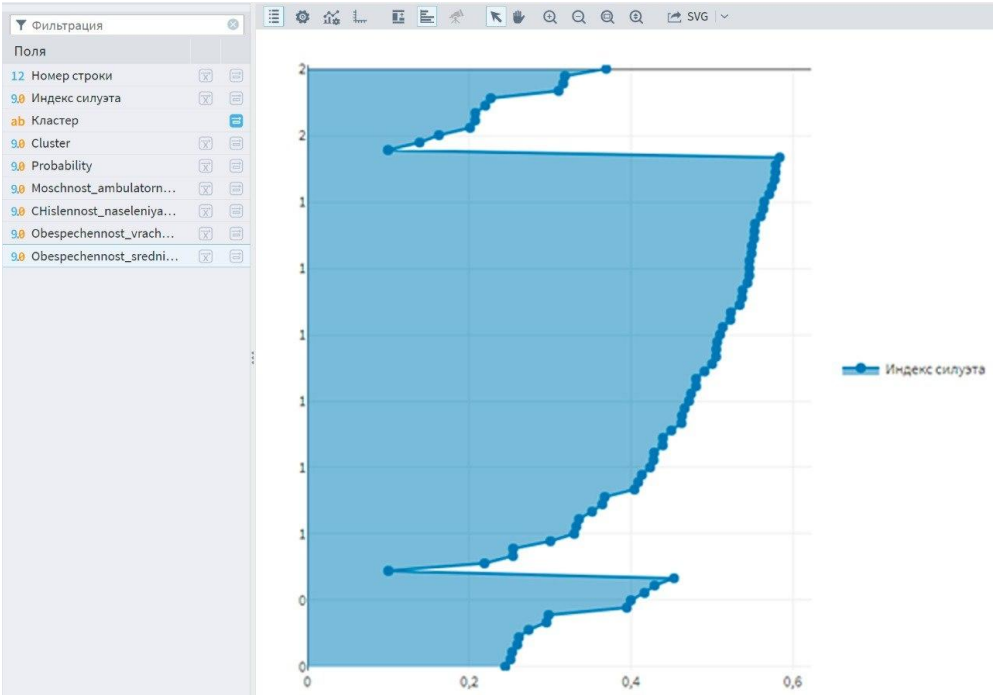

Рисунок 17 – Индекс силуэта (график)

Интерпретация полученных результатов позволяет выделить два основных типа регионов, сформированных на основе показателей высшего образования: регионы с высоким уровнем и регионы со средним уровнем.

К первой группе относятся территории со средними значениями масштаба системы высшего образования и средним уровнем обеспеченности профессорско-преподавательским составом.

Вторую группу составляют так называемые "студенческие" регионы, характеризующиеся исключительно высокой концентрацией студентов, а также повышенными показателями приема и выпуска.

Применение EM-алгоритма привело к существенно иным результатам. Центры кластеров и показатели качества модели представлены на рисунках 18 – 20.

	1. Число образовател...	2. Численность студенто...	3. Прием на обучение по ...	4. Выпуск бакалавров, сп...	5. Численность професс...
0	12,85	224,18	53,75	57,88	65,09
1	19,70	341,41	83,37	84,48	64,47
2	15,41	148,56	36,60	34,26	38,45
3	14,33	510,19	143,37	129,71	59,06
4	12,89	286,23	69,87	77,57	53,65

Рисунок 18 – Кластеризация здравоохранения методом EM

Имя	Метка	Значение
SilhouetteCoefficient	Индекс силуэта	0,29
Quality	Качество кластеризации	Среднее

Рисунок 19 – Показатели качества модели

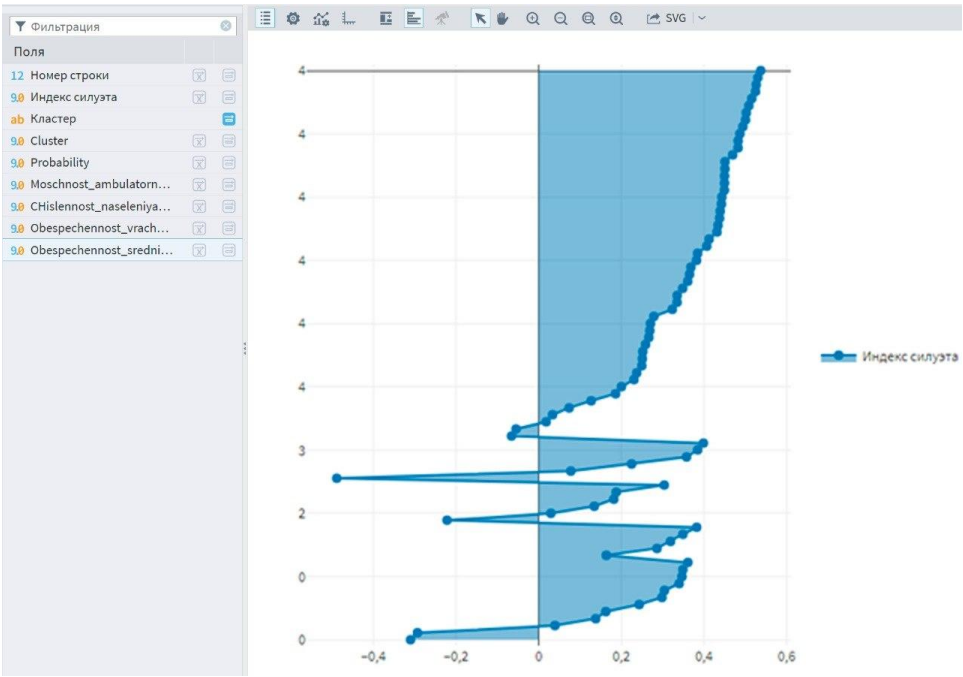

Рисунок 20 – Визуализация силуэтного индекса

Оценка качества построенной модели, а также данные графического анализа свидетельствуют о ее существенно более низкой эффективности по сравнению с моделью, построенной на основе k-means. Выделяется один крупный кластер и четыре менее многочисленных. На графике наблюдаются отрицательные значения, что указывает на принадлежность некоторых объектов к иным кластерам в сравнении с теми, в которые они были распределены. Значение коэффициента качества 0,29 характеризует кластеризацию как слабую.

Содержательная интерпретация выделенных кластеров представляется следующим образом. В кластер 0 вошли регионы с типичными значениями большинства показателей, но с повышенной численностью

преподавательского состава. Кластер 1 объединил территории с высокими значениями по всем параметрам и наибольшим количеством организаций высшего образования. Кластер 2 составляют регионы с низкими показателями по всем метрикам, то есть территории со слаборазвитой системой высшего образования. Кластер 3 включает регионы с высокой концентрацией студентов при средних показателях числа организаций и численности преподавательского состава. Кластер 4 представлен регионами, где все показатели находятся на среднем уровне.

Дополнительно была выполнена кластеризация транзакционных данных на основе чековой информации, результаты представлены на рисунке 21.

12 Номер кластера	12 N	12 W	12 S
0	93 559	17	476 204
1	81 690	7	236 001
2	64 238	3	120 142
3	12 041	1	17 773
4	38 701	3	158 568

Рисунок 21 – Кластеризация транзакций