

ГУАП

КАФЕДРА № 42

ОТЧЕТ
ЗАЩИЩЕН С ОЦЕНКОЙ
ПРЕПОДАВАТЕЛЬ

доцент, канд. техн. наук

должность, уч. степень, звание

подпись, дата

Н.В. Богословская

инициалы, фамилия

ОТЧЕТ О ЛАБОРАТОРНОЙ РАБОТЕ №9

ПЛАТФОРМА LOGINOM

по курсу: БОЛЬШИЕ ДАННЫЕ

РАБОТУ ВЫПОЛНИЛ

СТУДЕНТ гр. № 4321

подпись, дата

И.А. Лаврешин

инициалы, фамилия

Санкт-Петербург 2026

1. Цель работы

Реализовать полный цикл аналитического проекта в среде Logiном: от извлечения данных до построения и сравнения моделей машинного обучения (LOF и логистическая регрессия) для предсказания блокбастеров 2025 года на основе кассовых сборов с обогащением данных, очисткой, подготовкой признаков и визуализацией результатов.

2. Задание

Выполнить в Logiном полный цикл аналитического проекта: подключиться к базе данных Access, извлечь данные SQL-запросом, обогатить их справочником регионов, оценить и улучшить качество данных, выполнить нормализацию и квантование. Обучить модель LOF (novelty) и логистическую регрессию, выполнить тестирование и скоринг новых фильмов. Оценить качество моделей и сформировать отчёты.

3. Ход работы

Сначала были подготовлены данные в модуле “Подготовка выборок”, представленном на рисунке 1.




Рисунок 1 – Подготовка данных

Для хранения основной витрины использована локальная база MS Access data/movies.mdb с таблицей записей о фильмах 2025 года. В сценарии подготовки данных настроено постоянное подключение к этой базе и ссылка на него для повторного использования во всех последующих узлах импорта. Такой вариант соответствует требованию работы с собственной базой данных средствами Logiном.

Из таблицы фильмов в базе movies.mdb выполняется SQL-запрос на выборку всех полей. На выходе получается набор с полями режиссёра, названия фильма, кассовых сборов, популярности TMDb, активности в соцсетях и служебными идентификаторами. Этот поток далее проходит обогащение и очистку.




Рисунок 2 — Подключение к базе и импорт по запросу

После импорта основная таблица объединяется со справочником регионов режиссёров из CSV-файла `ref_artist_regions.csv`. Справочник содержит поля `artist`, `region` и `market_size`. Соединение выполнено по полю режиссёра: в основной таблице — `Artist`, в справочнике — `artist`. Тип соединения — `LEFT JOIN`: все фильмы из витрины сохраняются, регион и размер рынка подставляются там, где режиссёр найден в справочнике.




Рисунок 3 — Консолидация основной витрины и справочника

На этапе до обработки сформирован контрольный снимок `qc_before_cleaning.txt` — выгрузка таблицы для визуальной проверки «сырых» значений после `join`. В данных видны характерные проблемы: числа в

текстовом виде с запятой как десятичным разделителем, символ «?» вместо пропусков, смешение типов в колонках метрик.

Очистка выполнена цепочкой встроенных компонентов Loginom с минимальным числом произвольного кода только там, где визуальных средств недостаточно (парсинг формата чисел и квантование).

Очистка выполнена цепочкой встроенных компонентов Loginom. Узел «5. Очистка полей (изменение)» приводит структуру полей после объединения к единообразным именам и типам. «6. Пропуски (TBGDDataRecoveryEngine)» заполняет пропущенные значения. «7. Выбросы (TBGElimOutlierEngine)» ограничивает экстремальные значения по числовым метрикам. «9b. Числовые метрики» переводит строковые метрики в числа. «9с. Квантование ключевых метрик» строит пять порядковых бинов (0–4) для popularity, сборов и рейтинга фильма — поля q_popularity, q_streams, q_track_score. Контрольный снимок после квантования — qc_after_quantization.txt.

Целевая переменная IsHit задаётся правилом: 1, если Worldwide Gross не ниже ста миллионов, иначе 0. Дополнительно применён отбор «9. Отбор TMDb popularity ≥ 30 », чтобы оставить в анализе фильмы с заметной видимостью и снизить шум на «хвосте» низкой популярности. В финальной рабочей выборке около 3354 строк (train 2180, test 671, valid 503).




Рисунок 3 — Оценка качества и цепочка очистки

Данные разделены на обучающую, тестовую и валидационную части. Узел «8. Разбиение 80/20 (stratify IsHit)» делает стратифицированное разбиение по целевому классу. Метки SAMPLE: «9. SAMPLE = train» и «10. SAMPLE = test». «11. Объединение train + test» собирает поток обратно. «11b. SAMPLE = valid» выделяет из train около 18,75 % строк в валидацию (503 фильмов). Флаг IsTestSet истинен для test и valid. Итоговые объёмы зафиксированы в файле data/данные.txt. Публичный узел «Movies dataset (публичный)» передаёт подготовленный набор в сценарий моделирования.




Рисунок 4 — Разбиение выборок и передача в моделирование

В сценарии «Построение модели» импортируется файл data/данные.txt, сформированный модулем подготовки. «Очистка числовых полей» — дополнительная страховка от нечисловых значений перед масштабированием. Блок « $\sqrt{\text{meta-scaling}}$ » разделяет поток по SAMPLE и обучает преобразование только на train. « $\sqrt{\text{preprocessing.Scaler}}$ » применяет StandardScaler к числовым признакам (id=OBJECT, target=IsHit). Узлы «NaN после scaling» заменяют пустые значения после масштабирования на ноль.

Модель LOF настраивается в « $\sqrt{\text{neighbors.LOF Novelty}}$ »: Local Outlier Factor, режим novelty, n_neighbors=20, contamination=0,15. Обучение — узлом « $\sqrt{\text{model.fitter}}$ (выполнение)» на train; скоринг — на потоке test+valid.




Рисунок 5 — Нормализация и цепочка LOF

LOF выдаёт метку `outlier_label`: -1 — аномалия, $+1$ — норма. Для сравнения с `IsHit` в узле «Метки для metrics (0/1)» аномалия переводится в 1, норма в 0. Узел «Только test для metrics» оставляет строки с `IsTestSet=True` (test и valid, всего 1174 записей). Компонент «classification metrics (выполнение)» считает precision, recall, F1, accuracy и матрицу ошибок.

№	Метка
	Поиск
16	9.0 TikTok_Likes
17	9.0 TikTok_Views
18	9.0 YouTube_Playlist...
19	9.0 Apple_Music_Pla...
20	9.0 AirPlay_Spins
21	9.0 Deezer_Playlist_C...
22	9.0 Deezer_Playlist_R...
23	9.0 Amazon_Playlist_...
24	9.0 Pandora_Streams
25	9.0 Pandora_Track_S...
26	9.0 Explicit_Track
27	9.0 q_popularity
28	9.0 q_streams
29	9.0 q_track_score
30	9.0 q_popularity_1
31	9.0 q_streams_1
32	9.0 q_track_score_1
33	ab SAMPLE
34	0/1 Тестовое множе...
35	ab ISRC
36	ab Track
37	ab Album_Name
38	ab Artist
39	31 Release_Date
40	ab region
41	ab market_size
42	ab TIDAL_Popularity
43	9.0 Shazam_Counts
44	9.0 SiriusXM_Spins
45	9.0 Soundcloud_Stre...
46	ab OBJECT
47	12 IsHit

Рисунок 6 — Таблица метрик LOF

#	ab Метрика	9.0 Значение
1	precision	0,86
2	recall	0,90
3	f1_score	0,88
4	fbeta_score	0,89
5	accuracy	0,79
6	tn	48,00
7	fp	153,00
8	fn	97,00
9	tp	906,00

Рисунок 7 — Матрица ошибок LOF

По результатам на подвыборке test + valid (IsTestSet=True, 1174 фильма) компонент classification metrics выводит precision, recall, F1 и матрицу ошибок (см. рисунки 6–7). Интерпретация: LOF в постановке «аномалия = блокбастер» ищет фильмы с необычными комбинациями кассовых сборов, популярности TMDb и социальных метрик. Статистическая аномалия не совпадает один в один с бизнес-определением IsHit по порогу сборов, поэтому метрики отражают компромисс между полнотой и точностью.

Для учебной задачи важен полный цикл: ETL из Access, подготовка признаков, масштабирование, обучение LOF, расчёт метрик и сопоставление с целевой меткой блокбастера.

Помимо LOF реализована ветка логистической регрессии sklearn: тот же блок meta-scaling и scaler, затем «linear_model.LogisticRegression (LR)» и «model.fitter (LR sklearn)». На test метрики LR выводятся в узле classification metrics (см. рисунок 8).

Скоринг на новых данных выполнен отдельной веткой: «Импорт score CSV» — 459 фильмов из prepared_movies_score.csv; «Подготовка score» — приведение полей к схеме train, SAMPLE=score; «LR predict score (Python)» — q-бины и prob0/prob1; «Отчёт scoring LR» — сводка в report_scoring_lr.txt (459 строк, среднее prob1 ≈ 0.7310 , при пороге 0,5 предсказано 341 блокбастеров).

#	ab Метрика	9.0 Значение
1	precision	1,00
2	recall	0,79
3	f1_score	0,88
4	fbeta_score	0,82
5	accuracy	0,82
6	tn	198,00
7	fp	3,00
8	fn	215,00
9	tp	788,00

Рисунок 8 — Метрики логистической регрессии на test




Рисунок 9 — Скоринг новых фильмов (prob1)




Рисунок 10 — Итоговая схема модели

В подготовке данных настроены пользовательские отчёты по целевой метке IsHit и контрольные txt-снимки qc_before_cleaning.txt и qc_after_quantization.txt.




Рисунок 11 — Пользовательский отчёт: IsHit